Perform the following operations using Python on the Air quality data sets

a. Data cleaning b. Data integration c. Data transformation d. Error correcting e. Data model building

```
In [2]:
import pandas as pd
import numpy as np

In [5]:

df = pd.read_csv('AirQualityUCI.csv',sep=';')

In [6]:
```

Out[6]:

df

	Date	Time	CO(GT)	PT08.S1(CO)	NMHC(GT)	C6H6(GT)	PT08.S2(NMHC)	NOx	
0	10/03/2004	18.00.00	2,6	1360.0	150.0	11,9	1046.0	1	
1	10/03/2004	19.00.00	2	1292.0	112.0	9,4	955.0	1	
2	10/03/2004	20.00.00	2,2	1402.0	88.0	9,0	939.0	1	
3	10/03/2004	21.00.00	2,2	1376.0	80.0	9,2	948.0	1	
4	10/03/2004	22.00.00	1,6	1272.0	51.0	6,5	836.0	1	
9466	NaN	NaN	NaN	NaN	NaN	NaN	NaN		
9467	NaN	NaN	NaN	NaN	NaN	NaN	NaN		
9468	NaN	NaN	NaN	NaN NaN		NaN	NaN		
9469	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N	
9470	NaN	NaN	NaN	NaN	NaN	NaN	NaN		

9471 rows × 17 columns

a. Data cleaning

a.1 Removing Missing or Null Values:

```
In [10]:
```

```
df.dropna(axis=0,how='any')
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9471 entries, 0 to 9470
Data columns (total 17 columns):
#
    Column
                  Non-Null Count Dtype
                  -----
0
    Date
                 9357 non-null
                                  object
                 9357 non-null
1
    Time
                                  object
2
    CO(GT)
                 9357 non-null
                                object
3
    PT08.S1(CO) 9357 non-null
                                float64
4
    NMHC(GT)
                 9357 non-null
                                float64
              9357 non-null
5
                                  object
    C6H6(GT)
    PT08.S2(NMHC) 9357 non-null float64
6
7
    NOx(GT)
                  9357 non-null float64
                                  float64
8
    PT08.S3(NOx) 9357 non-null
9
                                  float64
    NO2(GT)
                  9357 non-null
    PT08.S4(NO2)
                  9357 non-null
                                float64
                                float64
    PT08.S5(03) 9357 non-null
12
    Τ
                  9357 non-null
                                object
13
    RH
                  9357 non-null
                                object
    ΑН
14
                  9357 non-null
                                  object
    Unnamed: 15
                  0 non-null
                                  float64
                                  float64
16 Unnamed: 16
                  0 non-null
dtypes: float64(10), object(7)
```

a.2 Reading and Removing Duplicate Values

· Reading Duplicates:

memory usage: 1.2+ MB

In [20]:

```
df.duplicated(subset=['CO(GT)'])
```

Out[20]:

```
False
0
        False
1
2
        False
3
         True
        False
         . . .
9466
         True
9467
         True
         True
9468
9469
         True
9470
         True
```

Length: 9471, dtype: bool

• Remove Duplicates:

In [24]:

df.drop_duplicates(keep=False)

Out[24]:

	Date	Time	CO(GT)	PT08.S1(CO)	NMHC(GT)	C6H6(GT)	PT08.S2(NMHC)	NOx		
0	10/03/2004	18.00.00	2,6	1360.0	150.0	11,9	1046.0	1		
1	10/03/2004	19.00.00	2	1292.0	112.0	9,4	955.0	1		
2	10/03/2004	20.00.00	2,2	1402.0	88.0	9,0	939.0	1		
3	10/03/2004	21.00.00	2,2	1376.0	80.0	9,2	948.0	1		
4	10/03/2004	22.00.00	1,6	1272.0	51.0	6,5	836.0	1		
9352	04/04/2005	10.00.00	3,1	1314.0	-200.0	13,5	1101.0	4		
9353	04/04/2005	11.00.00	2,4	1163.0	-200.0	11,4	1027.0	3		
9354	04/04/2005	12.00.00	2,4	1142.0	-200.0	12,4	1063.0	2		
9355	04/04/2005	13.00.00	2,1	1003.0	-200.0	9,5	961.0	2		
9356	04/04/2005	14.00.00	2,2	1071.0	-200.0	11,9	1047.0	2		
9357 rows × 17 columns										

localhost:8888/notebooks/chit3.ipynb#

a.3 Handling Outliers:

In [18]:

```
def remove_outliers(df,columns,n_std):
    for col in columns:
        print('Working on coloumn: {}'.format(col))

    mean = df[col].mean()
    sd = df[col].std()

    df = df[(df[col] <= mean+(n_std*sd))]
    return df

df</pre>
```

Out[18]:

	Date	Time	CO(GT)	PT08.S1(CO)	NMHC(GT)	C6H6(GT)	PT08.S2(NMHC)	NOx			
0	10/03/2004	18.00.00	2,6	1360.0	150.0	11,9	1046.0	1			
1	10/03/2004	19.00.00	2	1292.0	112.0	9,4	955.0	1			
2	10/03/2004	20.00.00	2,2	1402.0	88.0	9,0	939.0	1			
3	10/03/2004	21.00.00	2,2	1376.0 80.0 9,2		948.0	1				
4	10/03/2004	22.00.00	1,6	1272.0	51.0	6,5	836.0	1			
9466	NaN	NaN	NaN	NaN	NaN	NaN	NaN				
9467	NaN	NaN NaN Na		NaN	NaN	NaN	NaN				
9468	NaN	NaN NaN NaN Na		NaN	NaN	NaN					
9469	NaN	NaN	NaN	NaN NaN NaN		NaN					
9470	NaN	NaN	NaN	NaN	NaN	NaN	NaN				
9471 rows × 17 columns											

b. Data integration

```
In [26]:
```

```
df1 = pd.read_csv('heart.csv')
df1
```

Out[26]:

	age	sex	ср	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	са	thal	t
0	52	1	0	125	212	0	1	168	0	1.0	2	2	3	
1	53	1	0	140	203	1	0	155	1	3.1	0	0	3	
2	70	1	0	145	174	0	1	125	1	2.6	0	0	3	
3	61	1	0	148	203	0	1	161	0	0.0	2	1	3	
4	62	0	0	138	294	1	1	106	0	1.9	1	3	2	
1020	59	1	1	140	221	0	1	164	1	0.0	2	0	2	
1021	60	1	0	125	258	0	0	141	1	2.8	1	1	3	
1022	47	1	0	110	275	0	0	118	1	1.0	1	1	2	
1023	50	0	0	110	254	0	0	159	0	0.0	2	0	2	
1024	54	1	0	120	188	0	1	113	0	1.4	1	1	3	

1025 rows × 14 columns

In [27]:

pd.concat([df,df1])

Out[27]:

	Date	Time	CO(GT)	PT08.S1(CO)	NMHC(GT)	C6H6(GT)	PT08.S2(NMHC)	NOx
0	10/03/2004	18.00.00	2,6	1360.0	150.0	11,9	1046.0	1
1	10/03/2004	19.00.00	2	1292.0	112.0	9,4	955.0	1
2	10/03/2004	20.00.00	2,2	1402.0	88.0	9,0	939.0	1
3	10/03/2004	21.00.00	2,2	1376.0	80.0	9,2	948.0	1
4	10/03/2004	22.00.00	1,6	1272.0	51.0	6,5	836.0	1
1020	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
1021	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
1022	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
1023	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
1024	NaN	NaN	NaN	NaN	NaN	NaN	NaN	

10496 rows × 31 columns

c. Data transformation

```
In [30]:

dt = df.groupby(['CO(GT)','PT08.S1(CO)'])
dt.first()

Out[30]:
```

		Date	Time	NMHC(GT)	C6H6(GT)	PT08.S2(NMHC)	NOx(GT)
CO(GT)	PT08.S1(CO)						
-200	-200.0	25/05/2004	19.00.00	-200.0	-200,0	-200.0	-200.0
	681.0	15/11/2004	04.00.00	-200.0	0,4	428.0	24.0
	704.0	13/10/2004	03.00.00	-200.0	0,5	444.0	-200.0
	709.0	13/10/2004	04.00.00	-200.0	0,6	449.0	-200.0
	711.0	22/08/2004	15.00.00	-200.0	2,8	640.0	-200.0
9,2	1778.0	02/11/2004	20.00.00	-200.0	48,2	1935.0	859.0
9,3	-200.0	14/12/2004	18.00.00	-200.0	-200,0	-200.0	1310.0
9,4	1816.0	02/12/2004	19.00.00	-200.0	43,9	1851.0	1184.0
9,5	1908.0	26/10/2004	18.00.00	-200.0	52,1	2007.0	952.0
9,9	1881.0	13/12/2004	18.00.00	-200.0	50,8	1983.0	1479.0
6574 row	/s × 15 colum	ns					
4							>

d. Error correcting

e. Data model building

```
In [31]:
from sklearn.model_selection import train_test_split
train,test=train_test_split(df,random_state=0,test_size=.25)

In [32]:
print("Training Dataset:",train.shape)

Training Dataset: (7103, 17)

In [33]:
print("Testing Dataset:",test.shape)
```

Testing Dataset: (2368, 17)

In []: